



BIG DATA

2025/26

Ciclo	Especialización IA & BIG DATA
Nombre	Rodrigo Medina
Correo	YMQ06518@educastur.es
Nº Unidad Didáctica	03

BIG DATA

- PR_03.2

1.	APARTADO A.....	2
2.	APARTADO B	5
3.	APARTADO C	8
4.	APARTADO D	11
5.	APARTADO E	14

1. APARTADO A

Mediante un script de PIG, encontrar las cinco películas (código, título y número de votos) más votadas (recuento de votos, no media).

1. Describe informalmente los pasos que darás para llegar a la solución, por ejemplo:

1. Primero cargamos el dataset de u.data (votos) a través de LOAD, con sus campos definidos
2. Cargamos el dataset de u.item (movies) con los dos primeros campos (id y título)
3. Agrupamos las dos tablas por id de la película (movieId), quedándonos con un grupo diferente por cada película
4. A través del FOREACH, recorreremos cada grupo y sumamos de forma acumulativa la columna de rating (puntuaciones). Generamos una nueva lista con el título de cada película y su puntuación total, sumada de todas las votaciones
5. Ordenamos de forma descendente, de mayor a menor el resultado obtenido
6. Recortamos con LIMIT solo a los 5 primeros registros.
7. Almacenamos la salida obtenida en el sistema con STORE

2. Implementa en PIG el script necesario para obtener la información deseada.

--LOAD u.data

```
votes= LOAD 'pr03_2/u.data' USING PigStorage('\t') AS  
(userId:chararray,movieId:chararray,rating:int);
```

--LOAD u.item

```
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS  
(movieId:chararray,title:chararray);
```

BIG DATA

-- COGROUP (agrupamos las dos tablas por id de la película)

```
moviesGrupo = COGROUP movies BY movieId, votes BY
movieId;
```

--uso de FLATTEN despues de COGROUP

*mirar -txt

-- FOREACH votación total (sumar total puntuaciones)

```
totalVotes = FOREACH moviesGrupo GENERATE
group,movies.title,SUM(votes.rating) AS puntuacion;
```

-- ORDENAR de mayor a menor puntuación


```
ordenar = ORDER totalVotes BY puntuacion DESC;
```

--LIMIT (seleccionar 5 mas votadas)

```
top5movies = LIMIT ordenar 5;
```



--STORE (almacenar el resultado)

```
STORE top5movies INTO 'movies_analisis/top5movies' USING
PigStorage(',');
```



```
scriptMovies.pig
Archivo  Editar  Ver
--LOAD u.data
votes= LOAD 'pr03_2/u.data' USING PigStorage('\t') AS
(userId:chararray,movieId:chararray,rating:int);
--LOAD u.item
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS
(movieId:chararray,title:chararray);
-- COGROUP (agrupamos las dos tablas por id de la película)
moviesGrupo = COGROUP movies BY movieId, votes BY movieId;
-- FOREACH votacion total (sumar total puntuaciones)
totalVotes = FOREACH moviesGrupo GENERATE group,movies.title,SUM(votes.rating)
AS puntuacion;
-- ORDENAR de mayor a menor puntuación
ordenar = ORDER totalVotes BY puntuacion DESC;
--LIMIT (seleccionar 5 mas votadas)
top5movies = LIMIT ordenar 5;
--STORE (almacenar el resultado)
STORE top5movies INTO 'movies_analisis/top5movies' USING PigStorage(',');
Ln 9, Col 1  764 caracteres.  Texto sin formato  100%  Windows (CRLF)  UTF-8
```

3. Muestra la salida del mismo por pantalla y almacena también su resultado en un archivo en HDFS.



2. APARTADO B

Mediante un script de PIG, encontrar las diez películas mejor valoradas (código, título y media de puntuación) por los usuarios (ahora sí, media de todos los votos recibidos).

1. Describe informalmente los pasos que darás para llegar a la solución.

1. Primero cargamos el dataset de u.data (votos) a través de LOAD, con sus campos definidos
2. Cargamos el dataset de u.item (movies) con los dos primeros campos (id y título)
3. Agrupamos las dos tablas por id de la película (movieId), quedándonos con un grupo diferente por cada película
4. A través del FOREACH, recorreremos cada grupo y calculamos la media de la columna de rating (puntuaciones). Generamos una nueva lista con el título de cada película y su puntuación total, sumada de todas las votaciones.

Al generar los nuevos grupos, se añade el uso de FLATTEN para desempaquetar el título y poder mostrarlo de forma más estética en la salida, todo en una sola línea por registro

5. Ordenador de forma descendente, de mayor a menor el resultado obtenido
6. Recortamos con LIMIT solo a los 10 primeros registros.
7. Almacenamos la salida obtenida en el sistema con STORE

2. Implementa en PIG el script necesario para obtener la información deseada.

--LOAD u.data

```
votes= LOAD 'pr03_2/u.data' USING PigStorage('\t') AS
(userId:chararray,movieId:chararray,rating:int);
```

BIG DATA

--LOAD u.item

```
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS  
(movieId:chararray,title:chararray);
```

-- COGROUP (agrupamos las dos tablas por id de la película)

```
moviesGrupo = COGROUP movies BY movieId, votes BY  
movieId;
```

-- FOREACH (media puntuaciones)

-- Uso de FLATTEN para desempaquetar el titulo y poder mostrarlo más estéticamente

```
mediaVotes = FOREACH moviesGrupo GENERATE group,FLATTEN  
(movies.title) AS titulo ,AVG(votes.rating) AS media;
```

-- ORDENAR de mayor a menor media

```
ordenar = ORDER mediaVotes BY media DESC;
```

--LIMIT (seleccionar 10 películas con mas media)

```
top10moviesMedia = LIMIT ordenar 10;
```

--STORE (almacenar el resultado)

```
STORE top10moviesMedia INTO  
'movies_analisis/top10moviesMedia' USING PigStorage(',');
```

BIG DATA

```
scriptMoviesMedia.pig
Archivo  Editar  Ver

--LOAD u.data
votes= LOAD 'pr03_2/u.data' USING PigStorage('\t') AS
(userId:chararray,movieId:chararray,rating:int);

--LOAD u.item
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS
(movieId:chararray,title:chararray);

-- COGROUP (agrupamos las dos tablas por id de la película)
moviesGrupo = COGROUP movies BY movieId, votes BY movieId;

-- FOREACH (media puntuaciones)
-- Uso de FLATTEN para desempaquetar el titulo y poder mostrarlo más estéticamente
mediaVotes = FOREACH moviesGrupo GENERATE group,FLATTEN (movies.title) AS
titulo ,AVG(votes.rating) AS media;


-- ORDENAR de mayor a menor media
ordenar = ORDER mediaVotes BY media DESC;

--LIMIT (seleccionar 10 películas con mas media)
top10moviesMedia = LIMIT ordenar 10;

--STORE (almacenar el resultado)
STORE top10moviesMedia INTO 'movies_analisis/top10moviesMedia' USING
PigStorage(',');

Ln 1, Col 1 | 858 caracteres. | Texto sin formato | 100% | Windows (CRLF) | UTF-8
```

3. Muestra la salida del mismo por pantalla y almacena también su resultado en un archivo en HDFS.



Ambari Sandbox 0 ops 0 alerts Dashboard Services Hosts

> user > maria_dev > movies_analisis Total: 2 files or folders

Name >	Size >	Last Modified >	Owner >
top10moviesMedia	--	2025-11-18 19:22	maria_dev
top5movies	--	2025-11-18 18:46	maria_dev

File Preview

/user/maria_dev/movies_analisis/top10moviesMedia/part-v006-o000-r-00000

```
1201,Marlene Dietrich: Shadow and Light (1996) ,5.0
1293,Star Kid (1997),5.0
814,Great Day in Harlem, A (1994),5.0
1189,Prefontaine (1997),5.0
1467,Saint of Fort Washington, The (1993),5.0
1653,Entertaining Angels: The Dorothy Day Story (1996),5.0
1122,They Made Me a Criminal (1939),5.0
1536,Aiqing wansui (1994),5.0
1500,Santa with Muscles (1996),5.0
1599,Someone Else's America (1995),5.0
```


3. APARTADO C

Mediante un script de PIG, encontrar las cinco películas más antiguas con una valoración media por encima de 4 puntos.

1. Implementa en PIG el script necesario para obtener la información deseada.

--LOAD u.data

```
votes= LOAD 'pr03_2/u.data' USING PigStorage('\t') AS
(userId:chararray,movieId:chararray,rating:double);
```

--LOAD u.item

```
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS
(movieId:chararray,title:chararray,releaseDate:chararray);
```

-- COVERTIR fecha a tipo de dato :date) (ToDate())

```
moviesUpdate = FOREACH movies GENERATE
movieId,title,ToDate(releaseDate,'dd-MMM-yyyy') AS
releaseDate;
```

-- COGROUP (agrupamos las dos tablas por id de la película)

```
moviesGrupo = COGROUP moviesUpdate BY movieId, votes BY
movieId;
```

-- FOREACH (media puntuaciones)

-- Uso de FLATTEN para desempaquetar el titulo y poder mostrarlo más estéticamente

```
mediaVotes = FOREACH moviesGrupo GENERATE group,FLATTEN
(moviesUpdate.title) AS titulo
,FLATTEN(moviesUpdate.releaseDate) AS fecha,
ROUND(AVG(votes.rating)*100)/100.0 AS media;
```

BIG DATA

-- FILTER

```
moviesFilter = FILTER mediaVotes BY media >4.0;
```

-- ORDENAR por fechas (más antiguas)


```
ordenar = ORDER moviesFilter BY fecha;
```

--LIMIT (seleccionar 5 películas mas antiguas)

```
top5moviesOld = LIMIT ordenar 5;
```

--STORE (almacenar el resultado)

```
STORE top5moviesOld INTO 'movies_analisis/top5moviesOld'  
USING PigStorage(',');
```



The screenshot shows a code editor window titled 'scriptMoviesAntiguas.pig'. The editor contains a Pig script that loads data from 'pr03_2/u.data' and 'pr03_2/u.item', processes it to calculate average ratings, filters for ratings above 4.0, orders by release date, and stores the top 5 oldest movies. A status bar at the bottom indicates 'Ln 20, Col 37', '1.158 caracteres', '100%', 'Windows (CRLF)', and 'UTF-8'. A tooltip on the right says 'El documento se ha guardado por último'.

```
--LOAD u.data
votes= LOAD 'pr03_2/u.data' USING PigStorage('\t') AS
(userId:chararray,movieId:chararray,rating:double);

--LOAD u.item
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS
(movieId:chararray,title:chararray,releaseDate:chararray);

-- COVERTIR fecha a tipo de dato :date )(ToDate())
moviesUpdate = FOREACH movies GENERATE movieId,title,ToDate(releaseDate,'dd-MMM-yyyy') AS
releaseDate;

-- COGROUP (agrupamos las dos tablas por id de la película)
moviesGrupo = COGROUP moviesUpdate BY movieId, votes BY movieId;

-- FOREACH (media puntuaciones)
-- Uso de FLATTEN para desempaquetar el titulo y poder mostrarlo más estéticamente
mediaVotes = FOREACH moviesGrupo GENERATE group,FLATTEN (moviesUpdate.title) AS
titulo ,FLATTEN(moviesUpdate.releaseDate) AS fecha, ROUND(AVG(votes.rating)*100)/100.0 AS media;

-- FILTER
moviesFilter = FILTER mediaVotes BY media >4.0;

-- ORDENAR por fechas (más antiguas)
ordenar = ORDER moviesFilter BY fecha;

--LIMIT (seleccionar 5 películas mas antiguas)
top5moviesOld = LIMIT ordenar 5;

--STORE (almacenar el resultado)
STORE top5moviesOld INTO 'movies_analisis/top5moviesOld' USING PigStorage(',');
```

2. Muestra la salida del mismo por pantalla y almacena también su resultado en un archivo en HDFS.

Se muestra: movielf, título, fecha y puntuación media.

```
otal input paths to process : 1
(604,It Happened One Night (1934),1934-01-01T00:00:00.000Z,4.01)
(493,Thin Man, The (1934),1934-01-01T00:00:00.000Z,4.15)
(1203,Top Hat (1935),1935-01-01T00:00:00.000Z,4.05)
(615,39 Steps, The (1935),1935-01-01T00:00:00.000Z,4.05)
(613,My Man Godfrey (1936),1936-01-01T00:00:00.000Z,4.04)
```

File Preview

/user/maria_dev/movies_analisis/top5moviesOld/part-v006-o000-r-00000

```
604,It Happened One Night (1934),1934-01-01T00:00:00.000Z,4.01
493,Thin Man, The (1934),1934-01-01T00:00:00.000Z,4.15
1203,Top Hat (1935),1935-01-01T00:00:00.000Z,4.05
615,39 Steps, The (1935),1935-01-01T00:00:00.000Z,4.05
613,My Man Godfrey (1936),1936-01-01T00:00:00.000Z,4.04
```

4. APARTADO D

Mediante un script de PIG, encontrar la película mejor valorada por cada una de las ocupaciones (student, writer, doctor, etc.)

1. Implementa en PIG el script necesario para obtener la información deseada.

-- LOAD votaciones

```
votes = LOAD 'pr03_2/u.data' USING PigStorage('\t') AS  
(userId:chararray,movieId:chararray,rating:double);
```

-- LOAD movies

```
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS  
(movieId:chararray,title:chararray);
```

-- LOAD usuarios

```
users = LOAD 'pr03_2/u.user' USING PigStorage('|') AS  
(userId:chararray,age:int,gender:chararray,rol:chararray);
```

-- JOIN unimos las 3 tablas en una nueva tabla

```
data = JOIN votes BY userId, users BY userId;  
data = JOIN data BY votes::movieId, movies BY movieId;
```

-- FOREACH generamos un nuevo bag con los campos que necesitamos

```
dataNew = FOREACH data GENERATE movies::movieId AS  
movieId,movies::title AS titulo, users::rol AS rol,  
votes::rating AS rating;
```

BIG DATA

-- GRPOUP nuevo grupo por rol y tiulo

```
dataGroup = GROUP dataNew BY (rol, titulo);
```

-- FOREACH calculamos la media por cada grupo y lo extraemos en diferenets lineas
con flatten

```
mediaRating = FOREACH dataGroup GENERATE FLATTEN(group)  
AS (rol, titulo),AVG(dataNew.rating) AS media;
```

-- GROUP agrupamos por rol

```
grupoFinal = GROUP mediaRating BY rol;
```

-- FOREACH cada grupo lo ordenamos por media, y seleccionamos la primera
posicion

```
bestMovieRol = FOREACH grupoFinal {ordenar= ORDER  
mediaRating BY media DESC; bestMovie= LIMIT ordenar 1;  
GENERATE FLATTEN(bestMovie);};
```

-- STORE almacenmos salida

```
STORE bestMovieRol INTO 'movies_analisis/bestMovieRol'  
USING PigStorage(',');
```

-- 1. Unir votos con usuarios para obtener el 'rol' de quien votó
votes_users = JOIN votes BY userId, users BY userId;

-- 2. Unir el resultado anterior con películas para tener los títulos
full_data = JOIN votes_users BY votes::movielfd, movies BY movielfd;

-- 3. Agrupar por rol y título de película para calcular el promedio
grouped_data = GROUP full_data BY (users::rol, movies::title);

-- 4. Calcular la nota media por cada película y rol
avg_ratings = FOREACH grouped_data GENERATE
group.rol AS rol,
group.title AS title,
AVG(full_data.votes::rating) AS avg_score;

-- 5. Agrupar por rol para buscar la máxima puntuación dentro de cada uno
rol_group = GROUP avg_ratings BY rol;


-- 6. Seleccionar la película con el puntaje más alto por cada rol
best_by_rol = FOREACH rol_group {
sorted = ORDER avg_ratings BY avg_score DESC;
top_movie = LIMIT sorted 1;
GENERATE FLATTEN(top_movie);
};

2. Muestra la salida del mismo por pantalla y almacena también su resultado en un archivo en HDFS.

```

process : 1
(none,Tomorrow Never Dies (1997),5.0)
(other,Umbrellas of Cherbourg, The (Parapluies de Cherbourg, Les) (1964),5.0)
(artist,Wonderful, Horrible Life of Leni Riefenstahl, The (1993),5.0)
(doctor,Assignment, The (1997),5.0)
(lawyer,GoldenEye (1995),5.0)
(writer,Grosse Fatigue (1994),5.0)
(retired,Short Cuts (1993),5.0)
(student,Haunted World of Edward D. Wood Jr., The (1995),5.0)
(educator,Great Day in Harlem, A (1994),5.0)
(engineer,Umbrellas of Cherbourg, The (Parapluies de Cherbourg, Les) (1964),5.0)
(salesman,Glory (1989),5.0)
(executive,Dirty Dancing (1987),5.0)
(homemaker,Braveheart (1995),5.0)
(librarian,Fearless (1993),5.0)
(marketing,As Good As It Gets (1997),5.0)
(scientist,Rosencrantz and Guildenstern Are Dead (1990),5.0)
(healthcare,Man Without a Face, The (1993),5.0)
(programmer,Misérables, Les (1995),5.0)
(technician,Incognito (1997),5.0)
(administrator,Chairman of the Board (1998),5.0)
(entertainment,Englishman Who Went Up a Hill, But Came Down a Mountain, The (1995),5.0)
grunt>

```



5. APARTADO E

Mediante un script de PIG, encontrar el promedio de valoraciones por décadas, guardarlo en HDFS como un archivo csv. Posteriormente lo descargaremos a nuestro ordenador y con EXCEL hacer un gráfico de barras con los datos del fichero

1. Implementa en PIG el script necesario para obtener la información deseada.

-- LOAD votaciones

```
votes = LOAD 'pr03_2/u.data' USING PigStorage('\t') AS
(userId:chararray,movieId:chararray,rating:double);
```

-- LOAD movies

```
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS
(movieId:chararray,title:chararray);
```

-- FOREACH extraer el año del título usando regex_extract (substring no permite numero negativos)

```
moviesYear = FOREACH movies GENERATE movieId,
(int)REGEX_EXTRACT(title, '.*\\((\\d{4})\\)', 1) AS
releaseYear;
```

-- FOREACH calcular decada de cada año (/10*10) para obtener del año, la década

```
moviesDecade = FOREACH moviesYear GENERATE
movieId,(int)(releaseYear / 10) * 10 AS decade;
```

-- JOIN unir las películas con su década y las votaciones

```
data = JOIN votes BY movieId, moviesDecade BY movieId;
```

BIG DATA

-- GROUP agrupar por la década

```
groupDecade = GROUP data BY moviesDecade::decade;
```

-- FOREACH media de las votaciones por década (redondeo *100/100 para obtener sólo 2 decimales)


```
mediaRating = FOREACH groupDecade GENERATE group AS  
decade, (double)ROUND(AVG(data.votes::rating)*100)/100 AS  
media;
```

-- ORDER ordenar por década

```
ratingDecade = ORDER mediaRating BY decade ASC;
```

-- STORE almacenar

```
STORE ratingDecade INTO 'movie_analisis/ratingDecade'  
USING PigStorage(',');
```



```
scriptMoviesDecadas.pig  X  +  
Archivo  Editar  Ver  ⚙  
  
-- LOAD votaciones  
votes = LOAD 'pr03_2/u.data' USING PigStorage('\t') AS (userId:chararray,movieId:chararray,rating:double);  
  
-- LOAD movies  
movies = LOAD 'pr03_2/u.item' USING PigStorage('|') AS (movieId:chararray,title:chararray);  
  
-- FOREACH extraer el año del título usando regex_extract (substring no permite numero negativos)  
moviesYear = FOREACH movies GENERATE movieId, (int)REGEX_EXTRACT(title, '.*\\((\\d{4})\\)', 1) AS  
releaseYear;  
  
-- FOREACH calcular decada de cada año (/10*10) para obtener del año, la década  
moviesDecade = FOREACH moviesYear GENERATE movieId,(int)(releaseYear / 10) * 10 AS decade;  
  
-- JOIN unir las películas con su década y las votaciones  
data = JOIN votes BY movieId, moviesDecade BY movieId;  
  
-- GROUP agrupar por la década  
groupDecade = GROUP data BY moviesDecade::decade;  
  
-- FOREACH media de las votaciones por década (redondeo *100/100 para obtener sólo 2 decimales)  
mediaRating = FOREACH groupDecade GENERATE group AS decade, (double)ROUND(AVG(data.votes::rating)*100)/100 AS  
media;  
  
-- ORDER ordenar por década  
ratingDecade = ORDER mediaRating BY decade ASC;  
  
-- STORE almacenar  
STORE ratingDecade INTO 'movies_analisis/ratingDecade' USING PigStorage(',');
```

Ln 1, Col 1 | 1.201 caracteres. | Texto sin formato | 100% | Windows (CRLF) | UTF-8

BIG DATA

```
(1920,3.54)
(1930,3.93)
(1940,4.01)
(1950,3.94)
(1960,3.88)
(1970,3.87)
(1980,3.77)
(1990,3.39)
grunt> |
```

```
1920,3.54
1930,3.93
1940,4.01
1950,3.94
1960,3.88
1970,3.87
1980,3.77
1990,3.39
```

2. Abrir el archive en Excel y generar un gráfico de barras con los datos.

	A	B
1	decada	votacionMedia
2	1920	3,54
3	1930	3,93
4	1940	4,01
5	1950	3,94
6	1960	3,88
7	1970	3,87
8	1980	3,77
9	1990	3,39

